A/B-тест новой формы оплаты ЖКХ

Отчёт по результатам эксперимента, 1–30 апреля 2024 года.

1. Данные и обработка некорректных записей

В выгрузке 1 504 пользователя (A — 752, B — 751; форму открыли 751 и 750 пользователей) и 2 661 платёжная попытка. Дубликатов ключей и нарушений порядка шагов воронки нет. Некорректные записи обработаны так:

Запись	Обработка
Платёж без user_id (№ 99003)	Исключён: клиента и группу установить нельзя
Платёж № 99002: в платеже группа B, в профиле клиента — A	Использована группа из профиля: рандомизация шла по пользователям
Пользователь без группы (№ 9001)	Не включён в сравнение A/B
Возраст −5 и 150 (№ 9002, 9003); пропуск города (№ 9004)	Значения не использованы в сегментах, пользователи сохранены в основной метрике

Спорная запись № 99002 проверена отдельно: без неё разница равна +14,75 п.п. вместо +14,62 п.п. Выбросов по времени нет: интервалы между шагами составляют 1–13 минут; 158 из 5 497 интервалов, формально отмеченных правилом 1,5 IQR, лежат в этом диапазоне и сохранены.

2. Сравнение групп

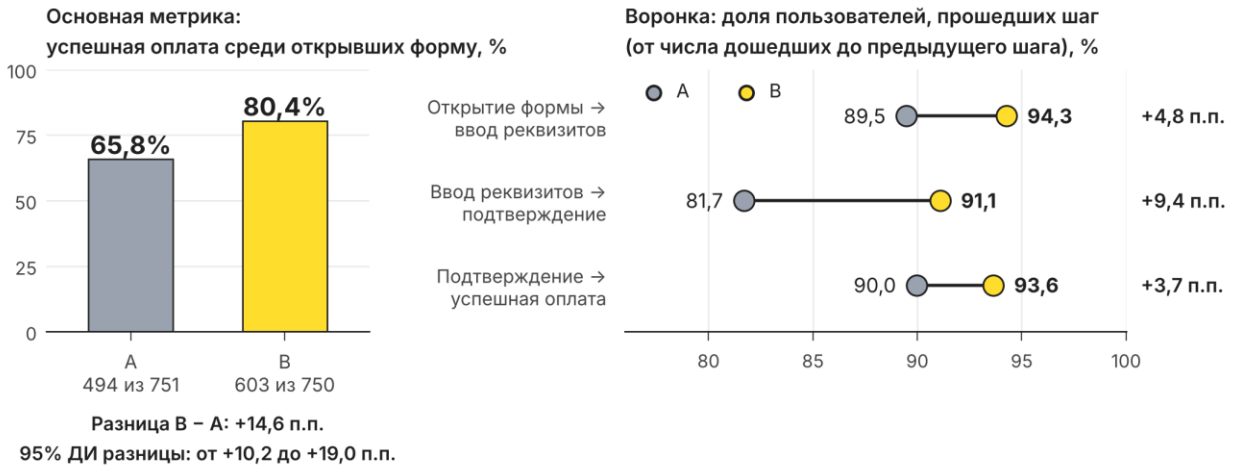


Рис. 1. Основная метрика и воронка оплаты на уровне пользователей.

Основная метрика — доля пользователей с успешной оплатой среди открывших форму: 494 из 751 в A и 603 из 750 в B. В ITT-анализе (знаменатель — все назначенные, 752 и 751) конверсия равна 65,7% и 80,3%, разница +14,6 п.п. (95% ДИ от +10,1 до +19,0).

3. Воронка оплаты

Доля прошедших переход выше в группе B на каждом этапе: открытие → ввод реквизитов 89,5% против 94,3% (+4,8 п.п.), ввод → подтверждение 81,7% против 91,1% (+9,4 п.п.), подтверждение → оплата 90,0% против 93,6% (+3,7 п.п.). После поправки Холма на три сравнения p = 0,0014; < 0,0001; 0,021. Каждый переход считается среди пользователей, дошедших до предыдущего шага, а их состав в группах мог уже различаться. Поэтому разницы показывают, где проявляется различие между группами, но не доказывают, на каком шаге форма действует. Медианное время от открытия до успешной оплаты одинаково в обеих группах (12 минут); это описательное наблюдение без отдельной проверки.

4. Статистическая проверка гипотезы

Проверялась нулевая гипотеза о равенстве долей успешных пользователей в A и B против двусторонней альтернативы ($\alpha = 0{,}05$). Единица анализа — пользователь: рандомизация проводилась по пользователям, а на одного приходится в среднем 1,8 попытки, поэтому попытки нельзя считать независимыми наблюдениями. Исход бинарный, группы независимы и содержат около 750 пользователей, поэтому применён z-тест для разности двух долей; доверительный интервал разницы построен методом Ньюкомба–Уилсона. Результат: +14,62 п.п., 95% ДИ от +10,16 до +19,00 п.п., $z = 6{,}39$, $p = 1{,}7 \cdot 10^{-10}$. Точный биномиальный тест на долю 50% не выявил отклонения от соотношения 50/50 (752 против 751, $p = 1{,}0$); плановое соотношение при этом документально не подтверждено.

5. Устойчивость результата

Оценка сохраняется при других способах расчёта (Рис. 2): только первая попытка пользователя +14,9 п.п.; логистическая регрессия с поправкой на устройство и город +14,5 п.п.; без попытки № 99002 +14,75 п.п.; уровень попыток с кластерным bootstrap по пользователям +14,6 п.п. (доля успешных попыток, а не пользователей). В перестановочном тесте метки групп 50 000 раз перемешивались между пользователями и 20 000 раз внутри типов устройств; значений, равных наблюдаемой разнице, не было ($p < 0{,}0001$). Поправка на устройство важна: доля iOS составляет 45,7% в A и 50,9% в B ($p = 0{,}053$), но на оценку это не влияет.

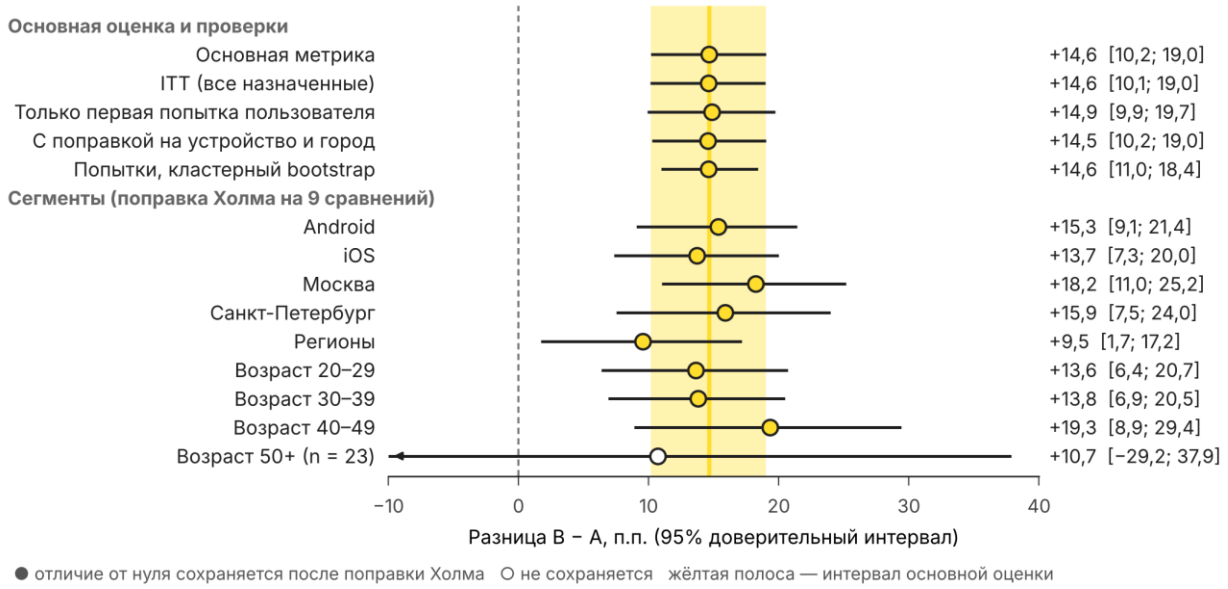


Рис. 2. Разница B − A и 95% доверительные интервалы: проверки устойчивости и сегменты.

6. Сегментный анализ

По устройству, городу и возрасту (9 сравнений, поправка Холма) оценка положительна во всех сегментах, значимы 8 из 9; исключение — возраст 50+ (23 пользователя), где интервал слишком широк. Меньше всего эффект в регионах (+9,5 п.п., ДИ от +1,7 до +17,2), больше всего в Москве (+18,2 п.п.). Взаимодействия группы с устройством ($p = 0{,}80$) и городом ($p = 0{,}20$) незначимы, но это не доказывает отсутствия различий между сегментами: выборки внутри них малы. Сегментные оценки исследовательские и не служат основанием для решения.

7. Рекомендация

Результаты поддерживают поэтапное масштабирование новой формы: увеличение доли тестовой группы с 25% до 50%, а затем до 90–95% трафика с сохранением 5–10% контрольной группы. Решение о полном запуске следует принимать после проверки защитных метрик на реальном трафике: возвраты и отмены, ошибки шлюза (включая платежи по неверным реквизитам), обращения в поддержку; пороги остановки нужно согласовать заранее. До старта необходимо подтвердить плановое соотношение групп 50/50, а для оценки окупаемости получить суммы платежей, маржу и затраты.